

Avaliando a Influência da Modelagem Relacional e Colunar no Gerenciamento de Ambientes OLAP por meio do TPC-H

1

Abstract.

Resumo. *Empresas têm utilizado ambientes de data warehouse (DW) e aplicações OLAP como apoio à tomada de decisão. Devido ao crescimento do volume de dados, meios mais eficientes para o seu processamento são necessários. SGBD relacionais ainda são bastante utilizados para tal, porém a abordagem NoSQL também vêm se consolidando no mercado. Para avaliar qual é o mais apropriado no gerenciamento de DW, um estudo comparativo entre os SGBD PostgreSQL e o NoSQL MonetDB é aqui apresentado a partir do benchmark TPC-H, com diferentes volumes de dados. O MonetDB se destacou em modelagens mais denormalizadas e o PostgreSQL em modelagens normalizadas; e de maneira geral, o MonetDB obteve desempenho superior ao PostgreSQL.*

1. Introdução

Para tomar decisões de maneira rápida e inteligente Organizações têm como base os dados armazenados em seus repositórios. Conforme o volume destes dados aumenta a má estruturação do repositório pode degradar o desempenho do acesso às informações, e devido a isso a tecnologia de Data Warehouses (DW) é utilizada para persistência de dados e tomada de decisões de forma eficiente.

Além do armazenamento de dados, é necessário que se tenha uma aplicação que os acesse e traga informações de maneira tão eficiente quanto à estruturação do repositório. Aplicações OLAP (*Online Analytical Processing*) analisam dados multidimensionalmente e executam consultas analíticas, fazendo com que estejam fortemente associadas à DW. Ao conjunto de DW e aplicações OLAP denomina-se ambiente OLAP.

Um ambiente OLAP deve ser projetado e implantado visando a rapidez na recuperação de dados [Wrembel and Koncilia 2007], [Codd et al. 1993], [Kimball and Ross 2002]. Sistemas Gerenciadores de Bancos de Dados (SGBD) surgem como uma solução para esta questão, e duas classes de SGBD podem atuar como gerenciadores de DW, os relacionais e os NoSQL. Para que haja uma conclusão sobre qual abordagem é a melhor, a aplicação de um benchmark torna-se pertinente, e no escopo de banco de dados um benchmark que se destaca por tratar de sistemas de suporte à decisão é o TPC-H [TPC-H 2017b].

Outro fator que interfere no desempenho de um ambiente OLAP é a forma como este é modelado. Ambientes normalizados são utilizados pela facilidade de manutenção, e o fácil entendimento acerca do relacionamento entre as entidades, que traz uma visão mais clara do sistema [Bax and Souza 2003]. Entretanto, modelos denormalizados surgem para trazer ganho no desempenho das consultas, por diminuir as junções entre tabelas devido ao menor número de entidades.

Dadas estas condições, o objetivo aqui é realizar um estudo comparativo entre um SGBD relacional e outro NoSQL como gerenciadores de DW utilizando o TPC-H. Devido a seu amplo uso e poucas modificações na linguagem SQL, foi definido o PostgreSQL como SGBD relacional e o MonetDB como NoSQL, este por ainda utilizar SQL, possuir interface simples e ser o pioneiro entre os bancos NoSQL colunares.

2. Recuperação e Persistência de Dados

Um DW é definido como uma coleção de dados não-volátil, orientado ao assunto da organização, integrado e variante no tempo [Inmon 2005]. Ele é a base para todos os sistemas de suporte a decisão, atualmente definido como ambiente OLAP, e sua estrutura consiste de um repositório de dados homogêneo, local e centralizado [Wrembel and Koncilia 2007].

É necessário que uma aplicação processe os dados contidos no repositório. DW trabalham sob uma grande massa de dados e executam consultas analíticas com base no suporte à decisão para acessar milhões de registros [Chaudhuri and Dayal 1997], visando a união de dados com informações úteis para o mercado. Devido a isso, histórico, taxa de vazão de consultas e o tempo de resposta são fatores importantes ao processar os dados do DW.

Aplicações OLAP estão diretamente ligadas a DW pois seus objetivos englobam identificar tendências, padrões de comportamento e anomalias, e ainda relações entre dados [Codd et al. 1993] sob um grande volume de dados. Suas consultas são longas, consomem grande tempo de execução e estão interessadas em atributos específicos; e o processo de inserção de dados segue um processo conhecido como ETL (extração, transformação e carga), sendo mais complexo que pequenas transações [Zelen 2017]. É neste processo que a modelagem conceitual do ambiente é definida. Ela tem como base a modelagem dimensional, ou multidimensional, fazendo uma analogia com um cubo para a representação de dados, uma vez que uma informação pode ser vista através de n dimensões. Em sua concepção, a modelagem dimensional é composta por tabelas fato e tabelas dimensão.

Fatos representam regras ou métricas de negócio, e geralmente são descritos como atributos numéricos, relacionados à quantidades; ou aditivos, pois uma aplicação nunca irá retornar somente um fato, mas sim vários onde a operação mais recorrente é a soma de atributos. Atributos textuais não definem um fato, na maioria das vezes apenas descrevem algo e são inseridos nas tabelas dimensão, que contem descrições a fim de tornar os fatos mais claros. Não é incomum encontrar tabelas dimensão com mais de 100 atributos e poucas tuplas, pois a intenção das dimensões é descrever as regras definidas por um fato. Nestas entidades são filtradas as consultas, compreendendo agrupamentos, padrões e ordenações, por exemplo.

Modelos dimensionais no escopo de um warehouse possuem apenas um fato com várias dimensões, fazendo com que sua estrutura se assemelhe a uma estrela, sendo conhecidos como modelos estrelas (*star*). Este modelo é simples e torna eficiente a recuperação de dados por ter um número menor de junções. Entretanto, com a afirmação de que modelos normalizados são mais fáceis para se dar manutenção, alguns modelos *star* podem ser trabalhados criando-se novas tabelas denominadas subdimensão. Estes modelos caracterizam modelagens relacionais e são conhecidos como modelos *snowflake*.

Para comparar o desempenho entre modelagens pode-se utilizar SGBD como ge-

enciadores de DW. Eles possuem algumas vantagens que os tornam úteis para tal, como controle de redundância, restrições de acesso, inserção de índices, restrições de integridade, possibilidade de realizar backup e restauração de dados, e persistência de dados garantida. Um modelo de SGBD muito conhecido e utilizado é o relacional. Esta classe está atrelada à dados mais normalizados por seguir a tradicional modelagem relacional, fazendo com que se aproxime do modelo *snowflake* de DW; e ainda preza pelos conceitos de ACID. Modelos assim definidos possuem algumas limitações quanto à escalabilidade, complexidade e o fato de todas as informações serem mantidas e recuperadas sob a forma de tuplas [Leavitt 2010]. Tais limitações podem degradar o desempenho de um ambiente analítico, visto que uma consulta analítica processa apenas os atributos necessários. Mesmo a adição de índices não ajudaria, devido a necessidade de ler estes índices [Matei and Bank 2010]. Para suprir estes problemas SGBD NoSQL podem ser utilizados.

O fortalecimento do movimento NoSQL se deu em 2007 com um artigo da Amazon sobre o banco Dynamo [DeCandia et al. 2007, Leavitt 2010], cujo objetivo era satisfazer algumas deficiências apontadas pelos SGBD relacionais, para tanto trabalham com modelagens de dados mais denormalizadas e podem ser classificados de diferentes formas de acordo com sua estruturação. Também, NoSQL tendem a não se ater ao ACID e optar por disponibilidade e particionamento de acordo com o teorema CAP [Brewer 2000] para realizar operações de forma mais rápida e possibilitar escalabilidade. O banco NoSQL que melhor trabalha ainda com a linguagem SQL é o modelo colunar. Seu diferencial é o armazenamento de todas as instâncias de um mesmo atributo junto. Isto reduz o tempo de acesso e escrita em disco [Matei and Bank 2010, Abadi 2008], retornando apenas os atributos solicitados; e também torna possível a compressão de dados [Abadi et al. 2006] e a eficiência em operações matemáticas de agregação [Matei and Bank 2010].

3. TPC-H

Para selecionar qual SGBD é o mais adequado a cada modelagem em ambientes OLAP a realização de um benchmark é o mais indicado. De acordo com seu manual de especificação [TPC-H 2017a], o TPC-H é um benchmark de suporte à decisão de negócios, representando grandes volumes de dados e executando consultas com um alto grau de complexidade a fim de responder questões críticas de negócio. Ele propõe uma modelagem *snowflake* que pode ser encontrada no manual do TPC-H [TPC-H 2017a].

O TPC-H não apresenta uma modelagem denormalizada de dados similar à *star*. Para tanto, foi construído um ambiente denormalizado a partir do ambiente original do TPC-H para as devidas comparações. Essa construção se fundamentou na criação de um modelo com uma única entidade fato central, unindo atributos de diferentes fatos, descrita por dimensões; e na remoção de tabelas subdimensão.

Cada SGBD é executado sobre os dois ambientes, *snowflake* e *star*. Em cada ambiente será executado o teste de desempenho, que é composto de duas execuções: o teste de força e o teste de vazão. Estas duas execuções são utilizadas para calcular o desempenho do SGBD, utilizando a unidade de medida *QphH@Size*, que corresponde à quantidade de consultas executadas por hora para determinado tamanho de banco de dados.

O primeiro teste, de força, mede a taxa de consultas por hora do sistema com um único usuário ativo. Neste teste são executadas em uma única sessão três instruções:

inserção de novos registros, consultas em SQL para recuperar informações, e remoção da mesma quantia de registros inseridos; exatamente nesta ordem. O segundo, o teste de vazão, mede a capacidade do sistema de processar a maior quantidade de consultas no menor intervalo de tempo. Sua execução se dá sob um número mínimo de sessões, também de acordo com o tamanho da base. É criada uma sessão para executar a inserção e remoção de dados, e n sessões para as consultas ao banco; sendo estas instruções executadas concorrentemente.

4. O Experimento

O estudo foi feito para bases de diferentes tamanhos, sendo estes de 1GB, 10GB e 30GB. Previamente foi analisado também o tempo para realizar a carga de dados nos SGBD. Logo ao analisar os resultados notou-se que uma base denormalizada leva mais tempo para o carregamento. Isto deve-se à redundância de dados de alguns atributos que antes eram tratados em entidades separadas, aumentando o tamanho das entidades das quais eles agora fazem parte.

O processo do TPC-H foi desenvolvido utilizando o driver JDBC devido a simplificação que seu uso traz ao desenvolvimento de aplicações e por dar suporte à vários SGBD. A execução começa com o teste de força seguido do teste de vazão, e estas execuções já mostram diferenças entre os SGBD, como visto na Tabela 1. O teste de força mostrou-se superior para todas as bases de dados, porém o teste de vazão, que testa como se comporta o sistema com mais de um usuário ativo através de execuções paralelas, apresenta comportamento diferente conforme a base aumenta, evidenciando um desempenho melhor do PostgreSQL sob o MonetDB.

Tabela 1. Valores dos testes de força e vazão para os cenários normalizados de teste

| SGBD | Base de Dados (GB) | | | Execução |
|------------|--------------------|-------|-------|----------------|
| | 1 | 10 | 30 | |
| MonetDB | 4.231 | 7.237 | 4.292 | Teste de Força |
| PostgreSQL | 2.022 | 1.120 | 0.781 | |
| MonetDB | 1622.929 | 3.305 | 0.125 | Teste de Vazão |
| PostgreSQL | 958.028 | 3.645 | 0.244 | |

Ao contrário do cenário normalizado, no denormalizado o MonetDB obteve valores superiores ao PostgreSQL em ambos os testes, conforme a Tabela 2 evidenciando que o MonetDB em ambiente denormalizado consegue ter ganhos ao normalizado para paralelismo; apesar disso algumas consultas do teste de força adaptadas do ambiente original do TPC-H demoraram mais que as originais, fazendo com que os resultados do normalizado sejam um pouco melhores ao denormalizado.

Tendo os valores de execução dos testes de força e vazão, estes foram aplicados no cálculo de desempenho final para o benchmarking. Analisando os ambientes isoladamente o MonetDB destacou-se na modelagem *star* por ser mais denormalizada, com ganhos de 11.11%, 6.43% e 5.53% para as bases de 1, 10 e 30GB. O PostgreSQL por ser um SGBD relacional teve destaque no ambiente *snowflake*, com ganhos de 53.44%, 177.39% e 117.32% para as mesmas bases. As Figuras 1(a) e 1(b) ilustram os resultados

Tabela 2. Valores dos testes de força e vazão para os cenários denormalizados de teste

| SGBD | Base de Dados (GB) | | | Execução |
|------------|--------------------|-------|-------|----------------|
| | 1 | 10 | 30 | |
| MonetDB | 3.435 | 4.643 | 3.253 | Teste de Força |
| PostgreSQL | 1.291 | 0.355 | 0.302 | |
| MonetDB | 2468.020 | 5.836 | 0.184 | Teste de Vazão |
| PostgreSQL | 637.310 | 1.495 | 0.134 | |

graficamente em conjunto de seus valores para o MonetDB e o PostgreSQL, respectivamente.




Figura 1. Ilustração dos resultados entre os SGBD

Tomando como base os ambientes e comparando os SGBD, o MonetDB obteve ganhos sob o PostgreSQL em todos os cenários. Este resultado era esperado se levar em conta o armazenamento e leitura aprimorados do MonetDB, apesar dos resultados apresentados pelo teste de força. Os ganhos para as respectivas bases foram de 88.29%, 142.04% e 67.66% no ambiente normalizado e 221.02%, 614.57% e 284.51% no ambiente denormalizado.




Figura 2. Ilustração dos resultados entre os ambientes

5. Conclusão e Trabalhos Futuros

Com alguns ganhos superiores à 100% no ambiente normalizado e todos superiores à 200% no denormalizado com seu melhor valor sendo 7 vezes melhor que o do Post-

greSQL, corrobora-se a ideia de que um SGBD NoSQL pode trazer vantagens para ambientes OLAP, por adaptar-se melhor à modelagem comumente utilizada por DW. Embora algumas consultas do ambiente denormalizado tenham levado um pouco mais de tempo para executar isso não interferiu de maneira crítica no benchmark.

Como continuidade para o projeto, propõe-se a inclusão de mais SGBD NoSQL de diferentes classes para que possa analisar se a mudança na estruturação de SGBD que não utilizam SQL para manipulação do banco tem impacto direto em ambientes empresariais. Exemplos destes são o MongoDB e o Neo4J, que possuem linguagem orientada a documento e grafo, respectivamente. Ainda, será realizada a aplicação dos resultados do estudo em empresas que utilizam uma modelagem relacional juntamente com SGBD relacionais, a fim de verificar se a mudança para um NoSQL sob modelagem denormalizada irá trazer vantagens à empresa.

Referências

- Abadi, D., Madden, S., and Ferreira, M. (2006). Integrating compression and execution in column-oriented database systems. In *Proceedings of the 2006 ACM SIGMOD international conference on Management of data*, pages 671–682. ACM.
- Abadi, D. J. (2008). *Query execution in column-oriented database systems*. PhD thesis, Massachusetts Institute of Technology.
- Bax, M. P. and Souza, R. (2003). Modelagem estratégica de dados: Normalização versus "dimensionalização". *KMBRASIL, Anais... São Paulo: SBGC*.
- Brewer, E. A. (2000). Towards robust distributed systems. In *PODC*, volume 7.
- Chaudhuri, S. and Dayal, U. (1997). An overview of data warehousing and olap technology. *ACM Sigmod record*, 26(1):65–74.
- Codd, E., Codd, S., and Salley, C. (1993). Providing olap (on-line analytical processing) to user-analysis: An it mandate. *White paper*.
- DeCandia, G., Hastorun, D., Jampani, M., Kakulapati, G., Lakshman, A., Pilchin, A., Sivasubramanian, S., Vosshall, P., and Vogels, W. (2007). Dynamo: amazon's highly available key-value store. In *ACM SIGOPS operating systems review*, volume 41, pages 205–220. ACM.
- Inmon, W. H. (2005). *Building the data warehouse*. John wiley & sons.
- Kimball, R. and Ross, M. (2002). *The Data Warehouse Toolkit: The Complete Guide to Dimensional Modeling*. Wiley Computer Publishing, 2 edition.
- Leavitt, N. (2010). Will nosql databases live up to their promise? *Computer*, 43(2).
- Matei, G. and Bank, R. C. (2010). Column-oriented databases, an alternative for analytical environment. *Database Systems Journal*, 1(2):3–16.
- TPC-H (2017a). *TPC BENCHMARK H Standard Specification. Revision 2.17.2*. Transaction Processing Performance Council, San Francisco. Acessado em: 12 de maio de 2017.
- TPC-H (2017b). Tpc-h homepage. Acessado em: 19 de maio de 2017.

Wrembel, R. and Koncilia, C. (2007). *Data warehouses and OLAP: concepts, architectures, and solutions*. Igi Global.

Zelen, A. (2017). Oltp vs. olap — what's the difference? Acessado em: 12 de abril de 2018.